



HUST

ĐẠI HỌC BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY OF SCIENCE AND TECHNOLOGY

ONE LOVE. ONE FUTURE.



ĐẠI HỌC
BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY
OF SCIENCE AND TECHNOLOGY

ĐỒ ÁN TỐT NGHIỆP

THIẾT KẾ VÀ XÂY DỰNG HỆ THỐNG QUẢN LÝ THƯ VIỆN TÍCH HỢP TRỢ LÝ ẢO

Sinh viên thực hiện: Vũ Thị Quỳnh Như

Mã số sinh viên: 20215110

Giáo viên hướng dẫn: TS. Đỗ Tuấn Anh

ONE LOVE. ONE FUTURE.

1. Đặt vấn đề
2. Mục tiêu đề tài
3. Phân tích yêu cầu
4. Thiết kế và triển khai hệ thống
5. Giải pháp và đóng góp nổi bật
6. Kết luận và hướng phát triển
7. Demo



1. Đặt vấn đề

ONE LOVE. ONE FUTURE.

1. Đặt vấn đề

- **Bối cảnh:** chuyển đổi số giáo dục, thư viện số ngày càng nhiều
 - **Khó khăn phổ biến:**
 - Mới dừng lại ở lưu trữ thông tin tĩnh, quản lý mượn trả đơn thuần
 - Độc giả gặp khó khăn khi tra cứu sâu nội dung bên trong sách, nội quy thư viện
 - **Hệ quả:**
 - Thủ thư quá tải; giảm hiệu suất khai thác sách; giảm sức hút với độc giả trẻ.
- > Cần một giải pháp tối ưu hóa vận hành, tự động hóa nghiệp vụ thư viện kết hợp Trợ lý ảo trực tuyến tương tác ngôn ngữ tự nhiên, phản hồi trung thực, chính xác với tri thức nội bộ thư viện



2. Mục tiêu đề tài

ONE LOVE. ONE FUTURE.

2.1. Mục tiêu đề tài


- Xây dựng hệ thống quản lý thư viện khép kín trực tuyến, giao diện thân thiện, dễ vận hành thực tế
- Tích hợp trợ lý ảo dựa trên kỹ thuật sinh tăng cường tìm kiếm (**RAG**) giúp trả lời chính xác, trung thực theo ngữ cảnh về nội dung sách và quy định thư viện



3. Phân tích yêu cầu

ONE LOVE. ONE FUTURE.

3.1. Biểu đồ Use Case – Mô tả yêu cầu chức năng hệ thống



3.2. Mô tả yêu cầu phi chức năng hệ thống

- **Hiệu năng:**
 - Tối ưu phản hồi (cập nhật cục bộ, không tải lại trang khi yêu thích, đánh giá)
- **Tính tin cậy:**
 - Bảo toàn tính toàn vẹn dữ liệu đối với mượn trả và cập nhật kho sách
- **Tính dễ sử dụng:**
 - Giao diện trực quan, thân thiện
 - Người dùng thao tác dễ dàng không cần hướng dẫn
- **Tính dễ bảo trì:**
 - Hệ thống dễ sửa lỗi, nâng cấp hoặc mở rộng
- **Tính bảo mật:**
 - Xác thực và phân quyền theo vai trò, ngăn chặn truy cập trái phép



4. Thiết kế và triển khai hệ thống

ONE LOVE. ONE FUTURE.

4.1. Lựa chọn kiến trúc phần mềm


Lựa chọn kiến trúc lai tách biệt dịch vụ bao gồm:

- Kiến trúc MVC tại Web App chính (Ruby on Rails)
- AI Chatbot Service (FastAPI / Python):
 - Thành phần: Chứa bộ não chính của RAG (RAGEngine), Vector DB (ChromaDB), Gemini LLM API.
 - Vai trò: Xử lý ngôn ngữ tự nhiên, tính toán tương đồng vector, gọi mô hình LLM.
- Giao tiếp: Kết nối thông qua HTTP RESTful API (Đầu vào định dạng JSON)


4.2. Thiết kế tổng quan

Biểu đồ gói tổng quan


- Gói **views**: Hiển thị giao diện
- Gói **controllers**: Xử lý logic nghiệp vụ
- Gói **models**: quản lý thực thể
- Gói **service(rag)**: gói dịch vụ AI xử lý các tác vụ hỏi đáp
- Gói **database**: lưu trữ dữ liệu có cấu trúc (PostgreSQL) , lưu trữ dữ liệu phi cấu trúc dạng vector nhúng (ChromaDB)



4.3. Thiết kế cơ sở dữ liệu



4.5. Thiết kế giao diện



Giao diện Trang chủ của độc giả tích hợp trợ lý ảo Thủ thư online

4.5. Thiết kế giao diện

The Book Oasis

Home

Search

Favorite

Borrow List

Nguyễn Văn An

04:41 AM
Wed, 07/08/2026

Hỗ trợ

Language

Your Borrow Cart

View Borrow Requests

Image	Book	Available Quantity	Author	Quantity	Select
	10 Điều Răn Về Những Thất Bại Trong Kinh Doanh	9	Donald R. Keough	1	☐ Remove

Borrow Date

07/07/2026

Return Date


14/07/2026

Borrow Books

Giao diện Giỏ sách mượn của độc giả



4.5. Thiết kế giao diện



Bảng điều khiển hoạt động dành cho Quản trị viên

4.5. Thiết kế giao diện

The Book Oasis

Dashboard

Users

Borrow Requests

Books

Authors

Categories

Publishers

Quản trị viên

04:45
08/07/2026

Hỗ trợ

Language

User Management

Name

Email

Status

Enter user name

Enter email

All

Search

No.	Name	Email	Action	Status
1	Trần Thị Tâm	tranthitam@example.com	View	Active
2	Nguyễn Văn Phong	nguyenvanphong@example.com	View	Active
3	Tạ Thị Hương	tatihuong@example.com	View	Active
4	Phan Văn Hòa	phanvanhoa@example.com	View	Active
5	Lương Thị Thanh	luongthithanh@example.com	View	Active
6	Trịnh Văn Phúc	trinhvanphuc@example.com	View	Active
7	Đặng Thị Nhung	dangthinhung@example.com	View	Active
8	Ngô Văn Huy	ngovanhuy@example.com	View	Active

Giao diện quản lý độc giả của thủ thư/ quản trị viên



4.5. Thiết kế giao diện

The Book Oasis

Dashboard

Users

Borrow Requests

Books

Authors

Categories

Publishers

Quản trị viên

04:46 AM
Wed, 07/08/2026

Hỗ trợ

Language

Borrow Requests Management

Username

Request From

Request To

Status

Enter username

dd/mm/yyyy

dd/mm/yyyy

All

Search

No.	Username	Request Date	Action	Status
1	Nguyễn Văn An	30/06/2026	View	Pending
2	Trần Thị Tâm	10/05/2026	View	Pending
3	Vũ Thị Kim	05/06/2026	View	Pending
4	Tạ Thị Thu	26/04/2026	View	Approved
5	Lương Thị Hạnh	03/05/2026	View	Returned
6	Phan Văn Hòa	14/06/2026	View	Pending
7	Phan Văn Hòa	18/06/2026	View	Borrowed
8	Trần Thị Vân	23/06/2026	View	Pending

Giao diện quản lý yêu cầu mượn trả của thủ thư/ quản trị viên



4.5. Thiết kế giao diện

The Book Oasis

Dashboard

Users

Borrow Requests

Books

Authors

Categories

Publishers

Quản trị viên

04:47
08/07/2026

Hỗ trợ

Language

Books Management

Add Book

Search by Title

Search

No.	Title	Total Quantity	Available Quantity	Action
1	Khóc Nửa Đêm Sớm Mai	45	18	View Edit Delete
2	Phù Lam	40	15	View Edit Delete
3	Phùng Thanh	30	10	View Edit Delete
4	Hôn Hoàng	35	12	View Edit Delete
5	Trẻ Em Tự Kỳ: Phương Thức Giáo Dục	35	14	View Edit Delete
6	Tuổi Dậy Thì – Giới Tính, Tránh Thai, BệnhẬT	60	30	View Edit Delete
7	Mặt Mả Tiểu Đường	40	18	View Edit Delete

Giao diện quản lý sách của thủ thư/ quản trị viên



5. Giải pháp và đóng góp nổi bật: Xây dựng hệ thống chatbot RAG

ONE LOVE. ONE FUTURE.

5.1. Đặt vấn đề và lý do lựa chọn RAG cho hệ thống chatbot thư viện


- **Mô hình LLM thông thường:** Bị giới hạn bởi ảo giác (Hallucination) và dữ liệu tĩnh (Outdated).
- **Đặc thù nghiệp vụ Thư viện:**
 - Dữ liệu bất đồng nhất: PDF sách (tĩnh, phi cấu trúc) vs SQL Database (số lượng sách, trạng thái mượn trả động).
 - Nội quy thư viện nghiêm ngặt: yêu cầu số liệu chính xác 100%.
 - Truy vấn mơ hồ: Bạn đọc thường hỏi tắt ("cuốn đó", "nó").
- **Mục tiêu thiết kế:** Xây dựng hệ thống RAG định tuyến đa nguồn, vừa đọc hiểu tài liệu tĩnh, vừa truy xuất dữ liệu tồn kho động theo thời gian thực.

5.1. Đặt vấn đề và lý do lựa chọn RAG cho hệ thống chatbot thư viện

Lợi ích mà RAG mang lại:

- **Tăng độ tin cậy:** Triệt tiêu ảo giác bằng cách đối chiếu tài liệu gốc.
- **Cập nhật liên tục:** Nhập sách, đổi nội quy chỉ cần cập nhật Vector DB, không cần huấn luyện lại LLM.
- **Khả năng giải thích (Explainability):** Trích dẫn rõ ràng tên sách, trang, chương hoặc điều khoản nội quy.
- **Tối ưu chi phí:** Sử dụng mô hình pre-trained lớn, chỉ tối ưu hóa Vector DB và mô hình nhúng cục bộ.
- **Tri thức chuyên biệt:** Giải quyết trọn tru các nội quy thư viện, tài liệu sách khác mà LLM công cộng chưa từng biết.

5.2. Kiến Trúc Tổng Quan và Luồng Xử Lý (Workflow)



5.3. Thiết Kế Mô-đun Truy Xuất (Retrieval Module)


- **Chiến lược Chunking : Phân mảnh phân cấp**
 - *Lý do:* Mảnh nhỏ dễ tìm kiếm chính xác (tránh nhiễu), mảnh lớn mới đủ ngữ cảnh cho LLM.
 - *Cách hoạt động:*
 - **Parent Chunks:** Kích thước 2000 ký tự (overlap 400), chứa ngữ cảnh đầy đủ để LLM đọc hiểu.
 - **Child Chunks:** Kích thước 400 ký tự (overlap 50), chứa chi tiết nhỏ để so khớp vector chính xác.
 - *Mối liên kết:* Mỗi mảnh Child lưu khóa parent_id trỏ đến mảnh Parent tương ứng.
- **Luồng xử lý:** Tìm kiếm khớp mảnh *Child* Lấy ID cha Truy xuất nội dung *Parent* gửi LLM.

5.3. Thiết Kế Mô-đun Truy Xuất (Retrieval Module)

Giải pháp tìm kiếm lai và tái xếp hạng tài liệu (Hybrid Search & Reranking)

- **Vấn đề:** Dense Vector (tìm kiếm ngữ nghĩa) dễ sai lệch với từ khóa viết tắt, mã sách. BM25 (Sparse) khớp từ khóa tốt nhưng bỏ qua ngữ cảnh.
- **Quy trình xử lý 2 giai đoạn (Hình 5.1):**
 - **Tìm kiếm lai (Hybrid Search):** Quét song song Dense Vector $K_VECTOR = 15$ và Sparse BM25 $K_BM25 = 10$. Gộp và chuẩn hóa điểm số theo trọng số $Alpha = 0.5$
 - **Tái xếp hạng (Cohere Rerank):** Đưa 25 đoạn qua mô hình rerank-multilingual-v3.0, dùng Cross-Encoder lọc lấy Top $N = 3$ đoạn tốt nhất gửi vào LLM.
- **Kết quả:** Nâng độ chính xác câu trả lời, tiết kiệm token, khắc phục "Lost in the Middle".

5.1. Giải pháp tìm kiếm lai và tái xếp hạng tài liệu (Hybrid Search & Reranking)




5.4. Thiết Kế Mô-đun Tạo Sinh: Định Tuyển & Prompt Đa Nhiệm

- **Vấn đề:** Độc giả có thể đưa ra rất nhiều loại câu hỏi -> Chạy RAG truy vấn vector cho mọi câu hỏi gây lãng phí tài nguyên CPU/GPU và dễ bị ảo giác tự bịa đặt thông tin không có thật
- **Giải pháp kỹ thuật:**
 - Thiết kế Intent Router dùng Gemini LLM (nhiệt độ temperature = 0.0) kết hợp cấu trúc đầu ra chặt chẽ Pydantic (IntentSchema).
 - Phân loại và định tuyển câu hỏi thành 4 nhánh xử lý (Hình 5.2):
 - **CHAT (Xã giao)** : Gửi thẳng cho LLM trả lời tự do.
 - **FIND_BOOK (Tra cứu danh mục)** :Gọi API tìm kiếm SQL của Rails, truy vấn SQL trực tiếp PostgreSQL -> Dữ liệu được trả về chính xác
 - **BOOK_INFO & POLICY (Nội dung/Nội quy)** Kích hoạt luồng RAG trên ChromaDB.
 - Với mỗi mỗi nhãn định tuyển câu hỏi sẽ có mẫu prompt riêng biệt để hướng dẫn LLM tạo ra đầu ra phù hợp

5.4. Thiết Kế Mô-đun Tạo Sinh: Định Tuyển & Prompt Đa Nhiệm

Sơ đồ định tuyến ý định
câu hỏi của Agent
Router





6. Kết luận và hướng phát triển

ONE LOVE. ONE FUTURE.

6.1 Kết luận

- Số hóa thành công quy trình nghiệp vụ thư viện trực tuyến khép kín 5 bước.
- Tích hợp trợ lý ảo RAG thông minh tương tác ngữ cảnh tự nhiên và loại bỏ ảo giác thông tin hiệu quả nhờ bộ định tuyến ý định.
- Tối ưu hóa xử lý dữ liệu lớn bất đồng bộ và tìm kiếm lai (Hybrid Search).
- Hạn chế:
 - Hệ thống chủ yếu mới được cấu hình và thử nghiệm trên môi trường cục bộ (localhost)
 - Đánh giá độ chính xác của mô hình RAG hiện tại mới chỉ dừng lại trên tập tài liệu mẫu mang tính thử nghiệm

6.2 Hướng phát triển

- Tích hợp khung đánh giá Ragas để định lượng chất lượng câu trả lời.
- Nâng cấp lên Multimodal RAG để phân tích biểu đồ, hình ảnh trong PDF.
- Xây dựng hệ thống gợi ý sách cá nhân hóa dựa trên lịch sử mượn đọc.
- Triển khai các LLM nguồn mở tại máy chủ local để bảo mật dữ liệu tuyệt đối, không bị giới hạn token

7. Demo

ONE LOVE. ONE FUTURE.



HUST

**Cảm ơn thầy cô
đã lắng nghe**

```
class RouterPrompts:
    """Từ điển 1: Phân loại câu hỏi (Đầu não định tuyến)"""
    SYSTEM_ROUTER = """
    Bạn là bộ phân loại yêu cầu cho thư viện HUST. Hãy phân tích câu hỏi của người dùng và trả về 1 trong các nhãn sau:

    - FIND_BOOK: Tìm danh sách sách, kiểm tra tác giả, vị trí sách trên kệ.
    - BOOK_INFO: Hỏi về nội dung, ý nghĩa, tóm tắt hoặc đánh giá sách.
    - POLICY: Hỏi về quy định mượn/trả, giờ mở cửa, thẻ thư viện.
    - CHAT: Chào hỏi hoặc nói chuyện không liên quan đến dữ liệu thư viện.

    Chỉ trả ra duy nhất tên nhãn (Ví dụ: FIND_BOOK), nghiêm cấm giải thích hoặc thêm dấu câu.
    """
```

```

class ExecutionPrompts:
    """Từ điển 2, 3, 4: Hệ thống Prompt xử lý theo ngữ cảnh RAG"""


    # 2. Từ điển Tra cứu (Search/Metadata Prompt)
    FIND_BOOK = """
    Bạn là một thủ thư tra cứu chính xác. Dựa trên NGỮ CẢNH cung cấp, hãy liệt kê danh sách các tác phẩm.
    Yêu cầu:
    1. Trình bày dạng danh sách có đánh số.
    2. Mỗi dòng gồm định dạng: [Tên sách] - [Tác giả].
    3. Nếu tìm thấy vị trí kệ (location) trong phần nguồn/metadata, hãy ghi chú ngay bên cạnh.
    4. Tuyệt đối không bình luận, tóm tắt hoặc phân tích thêm về nội dung sách trừ khi được yêu cầu.
    """

    # 3. Từ điển Giải đáp nội dung (Deep QA Prompt)
    BOOK_INFO = """
    Bạn là một chuyên gia phê bình văn học. Hãy sử dụng các đoạn trích trong NGỮ CẢNH để giải thích chi tiết vấn đề người dùng hỏi.
    Yêu cầu:
    1. Câu trả lời phải mạch lạc, giàu tính phân tích và bám sát nội dung trích dẫn.
    2. Nếu có nhiều luồng ý kiến hoặc thông tin nằm rải rác ở các đoạn trích khác nhau, hãy tổng hợp lại một cách logic.
    3. Phải trích dẫn rõ ràng tên tác phẩm hoặc tên chương khi đưa ra thông tin phân tích.
    """

    # 4. Từ điển Quy định & Thủ tục (Policy Prompt)
    POLICY = """
    Bạn là trợ lý hành chính của thư viện. Hãy trả lời các câu hỏi về nội quy một cách nghiêm túc, rõ ràng và chính xác.
    Yêu cầu:
    1. Nêu thật rõ các con số cụ thể (số ngày mượn, số tiền phạt, mốc thời gian...) có xuất hiện trong ngữ cảnh.
    2. Nếu quy trình gồm nhiều bước phức tạp, hãy liệt kê tường minh theo thứ tự 1, 2, 3.
    3. Nhắc nhở người dùng ngắn gọn về việc tuân thủ nội quy thư viện ở cuối câu trả lời.
    """

    # Dự phòng cho luồng hỏi thoại thông thường

```



5.3 Quy trình phân mảnh phân cấp và nạp dữ liệu bất đồng bộ

- **Vấn đề:** Tải lên các tệp sách PDF dung lượng lớn (10MB - 50MB) để nạp vào AI gây nghẽn luồng xử lý web chính (lỗi Gateway Timeout 504).
- **Giải pháp kỹ thuật:**
 - **Nạp dữ liệu bất đồng bộ:** Rails Active Storage nhận file ingestor_books.py chạy nền bất đồng bộ để trích xuất và tạo vector.
 - **Phân mảnh phân cấp (Hierarchical Chunking):**
 - Mảnh con (Child): 400 ký tự (chồng lợp 50 ký tự) - Tối ưu tìm kiếm vector.
 - Mảnh cha (Parent): 2000 ký tự - Cung cấp ngữ cảnh đầy đủ chiều sâu cho LLM.
 - Mảnh tóm tắt (Summary): Phục vụ các câu hỏi tóm tắt khái quát tác phẩm.
 - **BM25 Caching:** Lưu trữ chỉ mục BM25 dưới dạng tệp đệm nhị phân tuần tự hóa bm25_cache.pkl giúp tốc độ nạp sách mới chỉ mất dưới 15 giây.

5.3 Quy trình phân mảnh phân cấp và nạp dữ liệu bất đồng bộ

Hình 5.3: Quy trình số hóa sách PDF và đồng bộ Vector DB bất đồng bộ

